



# ***Indice de Sentimiento Corporativo***

## **IPSA 2021**

Guillermo Acuña  
Observatorio de Percepciones Económicas

## Resumen ejecutivo

En este reporte se presenta el Índice de Sentimiento Corporativo (ISC), un índice de confianza empresarial que analiza e interpreta la información contenida en las cartas a los accionistas de las empresas del IPSA, publicadas en las memorias corporativas del año 2020.

El índice se construyó en base a un modelo de machine learning, capaz de extraer el sentimiento implícito en las cartas a los accionistas, y clasificarlo como optimista o no optimista (pesimista o neutral). En concreto, el ISC mide el porcentaje de párrafos optimistas de las cartas a los accionistas, es decir, se trata de una media del grado de optimismo expresado por los presidentes de los directorios de las empresas del IPSA en sus cartas a los accionistas.

Se encontró un ISC promedio de 0.62, en una escala de 0 a 100. Las tres empresas con cartas más optimistas fueron Ripley, Cencosud y Falabella, mientras que las empresas con menor optimismo en sus cartas fueron Grupo Security, Engie y Banco Santander.

Por otro lado, se compararon las cartas de los presidentes de los directorios con las de los gerentes generales. Se encontró que en promedio los gerentes generales fueron más optimistas que los presidentes de los directorios, y que la diferencia fue más grande en el caso de las empresas con presidentes de directorio menos optimistas.

Por último, se calculó el ISC por industria. Se encontró que los sectores económicos más optimistas fueron el Comercio y la industria de Bebidas, mientras que los sectores menos optimistas fueron el de Servicios Básicos y el Financiero.

## Contenidos

Resumen ejecutivo .....	2
Contenidos .....	3
Introducción .....	4
Metodología .....	5
Base de datos .....	5
Procesamiento de los datos .....	5
Modelamiento .....	6
Clasificación .....	7
Generación de índices .....	8
Resultados .....	9
ISC por empresa .....	9
ISC de gerentes y presidentes .....	10
ISC por industria .....	11
Comercio .....	12
Financiera .....	13
Energía .....	14
Tecnología y Transporte .....	15
Servicios básicos .....	16
Bebidas .....	17
Manufactura .....	18
Conclusiones .....	19
Referencias .....	20
Anexos .....	21
Anexo 1. Empresas del IPSA y sus industrias .....	21
Anexo 2. ISC por empresa .....	22

## Introducción

En este trabajo se presenta el **Índice de Sentimiento Corporativo (ISC)**, un índice de confianza empresarial que analiza e interpreta la información implícita en las cartas a los accionistas, que anualmente publican las empresas en sus memorias corporativas.

Este trabajo se enmarca en la línea de la literatura económica iniciada por Baker, Bloom y Davis (2016), quienes elaboraron un índice de incertidumbre político-económica a partir de las noticias publicadas en los 10 mayores periódicos de EEUU. El índice refleja la frecuencia con que se encuentra un conjunto de palabras que señalan incertidumbre. En concreto, los artículos deben contener los siguientes tríos de palabras: *“economic”* o *“economy”*, *“uncertain”* o *“uncertainty”*, y uno o más entre *“congress”*, *“deficit”*, *“Federal Reserve”*, *“legislation”*, *“regulation”* o *“White House”*. Los autores demuestran en su investigación que el índice es capaz de predecir—a nivel de firmas—la volatilidad de los precios de las acciones, la inversión y el empleo en sectores económicos sensibles; y a nivel macro, la inversión agregada, actividad económica, y el empleo.

En Chile, se publica un índice similar, propuesto por Cerda, Silva y Valente (2018), investigadores de Clapes UC, quienes construyeron dos indicadores: un índice de incertidumbre económica, y un índice de incertidumbre político-económica. En particular destaca el índice de incertidumbre económica, que refleja la frecuencia de artículos de prensa que contengan las parejas de palabras: *“incertidumbre”* o *“incierto”* y *“economía”* o *“económico”*. Los artículos de prensa analizados se obtienen de El Mercurio, La Tercera y Diario Financiero. Los autores demuestran que el índice es capaz de predecir el PIB, el consumo, la inversión y el empleo.

Otros estudios similares en Chile son los de Becerra y Sagner (2020), quienes elaboraron un índice de incertidumbre económica en base a actividad de Twitter; y el de del Pilar, Peralta y Ávila (2020), quienes realizaron un análisis del sentimiento del Informe de Percepciones de Negocios del Banco Central de Chile.

En este estudio se realiza un análisis del sentimiento de las cartas a los accionistas que se publican anualmente en las memorias corporativas de las empresas del IPSA. La principal contribución de este trabajo es que, a diferencia de los otros estudios que interpretan la información implícita en los textos en base a un conjunto arbitrario de palabras, en este estudio la clasificación del sentimiento se realiza mediante algoritmos de Machine Learning, que seleccionan automáticamente las palabras que mejor reflejan los sentimientos optimistas. De esta manera, se busca que la clasificación del sentimiento económico encontrado en los textos sea lo más imparcial y completa posible, basada en patrones y combinaciones de palabras que se encuentran frecuentemente en los textos, y que pueden ser identificadas de forma eficiente y sistemática por los algoritmos.

El algoritmo se utilizó para identificar el sentimiento económico implícito en las cartas a los accionistas de las empresas del IPSA, y en base a esta clasificación se elaboró el índice de sentimiento corporativo (ISC).

## Metodología

El índice de sentimiento corporativo (ISC) se construyó a partir de la identificación del sentimiento económico implícito presente en las cartas a los accionistas del año 2020 de las empresas del IPSA. Por lo tanto, el primer paso en la elaboración del índice fue construir una base de datos que permitiera al algoritmo aprender a clasificar este tipo de sentimiento.

### Base de datos

Se construyó una base de datos de textos económicos, principalmente en base a noticias económicas publicadas en diversos medios prensa online durante abril de 2020 y abril de 2021. Las noticias fueron etiquetadas manualmente como pesimistas, neutrales y optimistas. Adicionalmente, la base de datos contiene fragmentos de cartas a los accionistas de años anteriores, en que claramente se observa una **polaridad**<sup>1</sup> específica: pesimista, neutral u optimista. En total la base de datos cuenta con 1.346 textos.

Los textos debían cumplir la condición de expresar claramente ideas con cierta polaridad, sin ambigüedades que pudieran confundir al algoritmo. Si, por ejemplo, un texto contenía una mezcla de ideas pesimistas y optimistas, se optaba por omitirlo, o bien se separaban los textos en fragmentos en con etiquetas individuales. Otra condición importante fue que los textos contuvieran información económica, de forma que las palabras y combinaciones de palabras encontradas coincidieran con las que pudiéramos encontrar en las cartas a los accionistas. En otras palabras, los textos debían contener la jerga mayormente utilizada en los ámbitos de la economía, negocios, finanzas, marketing, etc.

## Procesamiento de los datos

Los textos son datos no estructurados, ya que no tienen una estructura común. De hecho, cada texto es distinto de otro, en distintas dimensiones, por ejemplo: las palabras utilizadas, el número de caracteres, palabras o párrafos, combinaciones de palabras con significados específicos, etc. Por lo tanto, antes de utilizar estos datos se les debe dar una estructura.

Los textos fueron **pre-procesados** para darles estructura. En primer lugar, se simplificaron los textos, pasando todas las letras a minúsculas, retirando los números y caracteres especiales (signos de puntuación, exclamación, interrogación, paréntesis, comillas, etc.), se quitaron los acentos y las StopWords. Las StopWords son palabras sin un significado o sentido claro—como los artículos, pronombres y preposiciones—que se usan con frecuencia en todo tipo de textos, independientemente de la polaridad, por lo que no contribuyen a diferenciar los distintos sentimientos.

Luego, los textos fueron **vectorizados**, lo que significa representar su contenido en una matriz. Con este objetivo se crea el *vocabulario* de la base de datos, que es una lista de todas las palabras presentes en el total de textos. Dichas palabras pasan a ser los nombres de las columnas de la matriz. Por otro lado, cada fila de la matriz representa un texto, y los valores de las celdas indican si cada palabra del vocabulario aparece o no en el texto correspondiente.

La vectorización puede hacerse de distintas maneras. Por ejemplo, además de las palabras individuales se pueden considerar *n-gramas*, que son combinaciones de palabras consecutivas. Esto es importante, ya que una palabra como *desempleo* podría tener una

---

<sup>1</sup> Los conceptos *polaridad* y *sentimiento* se usan como sinónimos.

connotación negativa, pero su sentido cambia a positivo si se combina con otra palabra. Por ejemplo, *desempleo disminuye*. Por otro lado, los valores que indican si una palabra aparece o no en un texto también pueden variar. Se puede usar el número de veces que cada palabra aparece en un texto, la frecuencia porcentual con que cada palabra aparece, o la medida Tf-idf (*term frequency – Inverse document frequency*), que multiplica la frecuencia con que cada palabra aparece por el inverso de la frecuencia con que aparece en el total de textos, lo que hace que las palabras muy comunes tengan un menor peso en la matriz.

En este estudio se optó por usar seis combinaciones distintas de parámetros:

1. El vocabulario lo componen las 3000 palabras más frecuentes, y los valores son el número de veces que aparece cada palabra en cada texto.
2. El vocabulario lo componen las 3000 palabras y pares de palabras consecutivas (n-gramas=1,2) más frecuentes, y los valores son el número de veces que aparecen en cada texto.
3. El vocabulario lo componen las 3000 palabras más frecuentes, y los valores son la frecuencia porcentual con que aparece cada palabra en cada texto (número de veces que aparece la palabra dividido por el total de palabras en el texto).
4. El vocabulario lo componen las 3000 palabras y pares de palabras consecutivas (n-gramas=1,2) más frecuentes, y los valores son la frecuencia porcentual con que aparecen en cada texto (número de veces que aparece el n-grama dividido por el total de n-gramas en el texto).
5. El vocabulario lo componen las 3000 palabras más frecuentes, y los valores son la Tf-idf de cada palabra.

6. El vocabulario lo componen las 3000 palabras y pares de palabras consecutivas (n-gramas=1,2) más frecuentes, y los valores son la Tf-idf de cada n-grama.

Por último, se procesó la **variable dependiente**, que es la etiqueta dada a los textos (pesimista / neutral / optimista). Se usó el número 1 para distinguir los textos optimistas, y un 0 en otro caso. Esto implica que el algoritmo se entrenó para identificar textos con sentimiento positivo. El 21% de las etiquetas de la base de datos son optimistas, mientras que el restante 79% son pesimistas o neutrales.

### Modelamiento

Dado que se cuenta con seis distintos conjuntos de datos, preprocesados de formas diversas, se utiliza un **Stacking** de modelos de clasificación, una técnica de *ensemble learning*, que implica ajustar un conjunto de modelos individuales a cada base de datos, cuyas predicciones luego son combinadas por un metamodelo, que entrega la predicción final. Los modelos de ensemble learning típicamente tienen un mejor desempeño que los modelos individuales, ya que permiten combinar las predicciones generadas por los modelos individuales de forma de obtener lo mejor de cada una.

El primer paso del modelamiento fue **separar la muestra** en tres subconjuntos de datos, seleccionados de forma aleatoria y estratificada, de forma tal que la distribución de la variable dependiente fuera la misma en cada subset. Los subsets tienen 874, 377 y 95 textos cada uno, es decir, 65%, 28% y 7% de los datos, respectivamente. Esta separación de la muestra se hizo para cada una de las seis matrices de datos.

El subset 1 se usó para **entrenar los modelos individuales**, seis regresiones logísticas, una para cada matriz de datos. Luego, cada uno de

los modelos generó predicciones para los subsets 2 y 3. A continuación, se entrenó el metamodelo usando el subset 2, es decir, usando las predicciones de los primeros seis modelos para el subset 2 como inputs, y usando la variable dependiente del subset 2. Finalmente, se evaluó el desempeño de los modelos en el subset 3. Esta estrategia permite reducir el sobreajuste de los modelos a los datos.

Para **calibrar** los modelos se usó *k-fold cross validation* con  $k=5$  y una búsqueda de grilla. La validación cruzada (*cross-validation*) significa que cada modelo se ajusta  $k$  veces, usando un  $(k-1)/k\%$  de los datos, luego se hace una predicción para la parte excluida y se calcula una medida de error. De esta manera se obtienen  $k$  medidas de error, que se promedian para obtener una estimación del error fuera de la muestra (CV-Error). La métrica de error utilizada fue la *Accuracy*, que es el porcentaje de datos correctamente clasificados sobre el total de datos. La búsqueda de grilla significa repetir el procedimiento para una serie de valores de parámetros exógenos, que en el caso de la regresión logística pueden ser: (1) tipo de regularización, Lasso o Ridge, y (2) el parámetro asociado a la regularización ( $\lambda$ ). Se probaron 20 posibilidades para el valor  $\lambda$ , que junto con los dos posibles métodos de regularización significó probar 40 combinaciones para cada uno de los seis modelos individuales. De esta manera se seleccionó la combinación óptima de parámetros, que es aquella que minimiza el CV-Error.

A continuación, una vez elegidos los mejores modelos, se ajustaron a los subsets 1 completos, y se hizo la predicción para los subsets 2 y 3. Luego, se repitió la búsqueda de grilla con *cross-validation* para el

**metamodelo**, de forma de seleccionar sus parámetros óptimos. El metamodelo también es una regresión logística, y se buscó en la misma grilla utilizada de los modelos individuales. Una vez elegido el mejor metamodelo, se ajustó al subset2 completo y se hizo la predicción para el subset 3.

El último paso fue **optimizar el threshold**. El metamodelo entrega como predicción la probabilidad de que un texto sea optimista, que es un valor entre 0.0 y 1.0. Para hacer una predicción de las etiquetas [0, 1] se necesita un *threshold* (umbral) tal que una probabilidad mayor al threshold se considere como un 1 (etiqueta positiva). Para optimizar el threshold se hizo una búsqueda de grilla sencilla, en 200 valores equidistantes entre 0 y 1. Se optimizó usando como referencia la métrica *F1*, que es la media armónica de otras dos métricas *precision* (porcentaje de los datos clasificados como positivos por el modelo que son efectivamente positivos) y *recall* (porcentaje de los datos efectivamente positivos que fueron clasificados como positivos por el modelo).<sup>2</sup>

El objetivo de la calibración es elegir la combinación de parámetros exógenos (tipo de regularización,  $\lambda$ , threshold) que produzca los mejores resultados de acuerdo con las métricas de error utilizadas. Una vez que ya se tienen especificados los mejores modelos, éstos se ajustan a la muestra completa, es decir, al 100% de los datos disponibles.

## Clasificación

El siguiente paso en la elaboración del ISC fue preprocesar las cartas a los accionistas, que se obtuvieron de las memorias corporativas del año 2020 de las empresas del IPSA.

---

<sup>2</sup> Precision =  $TP / (TP + FP)$  donde TP=True Positives y FP=False Positives, y Recall =  $TP / (TP + FN)$  donde FN = False Negatives. Una alta precision indica

pocos falsos positivos, y una baja recall indica pocos falsos negativos.

Primero se **separaron las cartas por párrafo**. De esta manera, cada párrafo se consideró como un texto individual, que luego fue clasificado por el algoritmo. Esto se hizo así por varios motivos: (1) los textos de las memorias son principalmente optimistas, por lo que si se hubiera optado por clasificar las cartas completas todas habrían sido optimistas, (2) aunque las cartas sean principalmente optimistas, pueden contener párrafos pesimistas, neutrales y optimistas, por lo que clasificar cada párrafo por separado permite medir el grado de optimismo de cada carta—la forma de agregar las clasificaciones por texto es obtener el porcentaje de párrafos optimistas sobre el total de párrafos. Así, también se logra un tercer objetivo (3) normalizar por la extensión de las cartas, ya que algunas cartas son mucho más extensas que otras.

A continuación, se procesaron los párrafos de la misma manera que se hizo con los textos económicos. Primero se simplificaron los textos retirando números, caracteres especiales, acentos, StopWords, etc. Luego se vectorizaron los textos, usando los mismos vectorizadores que se utilizaron con los textos económicos. De esta manera, se generaron las seis matrices, que son los inputs de los modelos individuales que alimentan al metamodelo, que finalmente entrega la clasificación para cada párrafo.

### Generación de índices

Finalmente, el modelo entregó la clasificación para cada párrafo, es decir, la extracción del sentimiento económico. El algoritmo genera, para cada empresa, una lista de párrafos clasificados como 1 (optimista) o 0 (no optimista), cuyas etiquetas se promediaron para obtener los índices por empresa. Por lo tanto, el **índice de sentimiento corporativo es**

### el porcentaje de párrafos optimistas de las cartas a los accionistas.

Las empresas del IPSA y las industrias a las que pertenecen se pueden encontrar en el anexo 1. Se menciona que se excluyó la empresa SQM de los cálculos, ya que es la única empresa de la lista que no publicó una carta a los accionistas.

Por otro lado, se menciona que algunas empresas publicaron más de una carta. En las memorias corporativas siempre se encuentra una carta del **presidente del directorio**, pero en algunos casos los gerentes generales (o ejecutivos con títulos similares) también publican cartas a los accionistas y stakeholders. En el siguiente cuadro se muestra que esta es una práctica común en las empresas del comercio y finanzas.

*Cuadro 1. Cartas por industria y autor*

Industria	Gerente	Presidente
Bebidas	0	3
Comercio	6	7
Energía	1	4
Financiera	4	6
Manufactura	0	2
Servicios Básicos	1	3
Tecnología y Transporte	0	4

**El ISC se elabora oficialmente a partir de las cartas a los accionistas de los presidentes de los directorios**, pero también se calcularon los índices para las cartas de los gerentes generales, con fines de comparación.

Adicionalmente se calcularon **índices por industria**. El cálculo se realizó promediando los índices por empresas.

Por último, el **ISC del IPSA** se calculó promediando los índices por empresa de la lista completa de empresas del IPSA.




## Resultados

### ISC por empresa

En el gráfico 1 se observa el **ISC por empresa**, de mayor a menor. El cuadro con los resultados numéricos se encuentra en el anexo 2. Se observa que las tres empresas con las cartas más optimistas fueron Ripley, Cencosud y Falabella. Se destaca que todas estas empresas integran el sector del Comercio, pese a que fue uno de los más afectados por la pandemia durante el año 2020. Por el contrario, las empresas menos optimistas fueron Grupo Security, Engie y Banco Santander.

Gráfico 1. ISC por empresa



La línea vertical roja muestra el **ISC promedio**, que fue de 0.62. Es interesante identificar qué empresas se ubicaron por sobre y por debajo del promedio. En particular destaca que la mayoría de las empresas del Comercio se ubicaron por sobre el promedio de optimismo.

### ISC de gerentes y presidentes

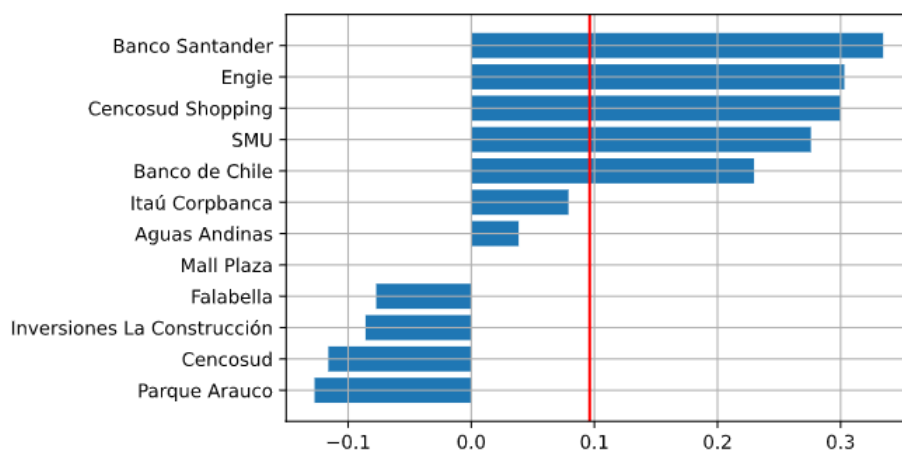
En el siguiente cuadro se observa el ISC calculado a partir de las cartas de los Gerentes Generales, y se compara con el ISC de los Presidentes de Directorio. Se puede apreciar que en promedio los gerentes generales fueron más optimistas en sus cartas que los presidentes de directorio.

*Cuadro 2. ISC de Gerentes y Presidentes*

Nombre	Industria	Gerentes	Presidentes	Diferencia
SMU	Comercio	1.00	0.72	0.28
Cencosud	Comercio	0.81	0.93	-0.12
Cencosud Shopping	Comercio	0.80	0.50	0.30
Falabella	Comercio	0.79	0.87	-0.08
Mall Plaza	Comercio	0.76	0.76	0.00
Banco Santander	Financiera	0.74	0.41	0.33
Banco de Chile	Financiera	0.68	0.45	0.23
Engie	Energía	0.67	0.36	0.30
Inversiones La Construcción	Financiera	0.64	0.72	-0.09
Parque Arauco	Comercio	0.60	0.73	-0.13
Itaú Corpbanca	Financiera	0.58	0.50	0.08
Aguas Andinas	Servicios Básicos	0.50	0.46	0.04
<b>Promedios</b>		<b>0.71</b>	<b>0.62</b>	<b>0.10</b>

En el siguiente gráfico se visualiza la diferencia (ISC gerentes – ISC presidentes). Un hallazgo interesante es que las mayores diferencias positivas, es decir, los casos en que los gerentes fueron mucho más optimistas que los presidentes, se encontraron en dos de las empresas con cartas de presidentes más pesimistas: Banco Santander y Engie.

*Gráfico 2. Diferencia de ISC de gerentes y presidentes*



## ISC por industria

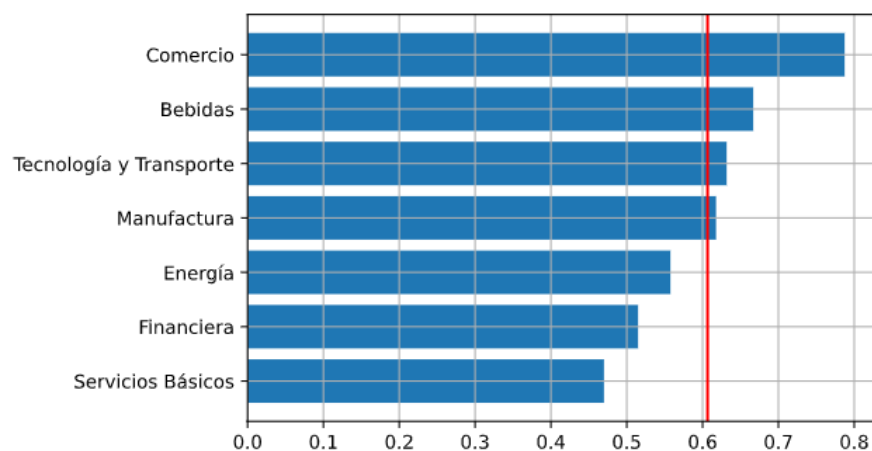
En el siguiente cuadro se muestra el ISC por industria, ordenado de mayor a menor. Se observa que las industrias más optimistas en promedio fueron las del Comercio y Bebidas, mientras que las menos optimistas fueron los sectores de servicios básicos y financiero.

*Cuadro 3. ISC por industria*

Industria	ISC
Comercio	0.79
Bebidas	0.67
Tecnología y Transporte	0.63
Manufactura	0.62
Energía	0.56
Financiera	0.51
Servicios Básicos	0.47

En el gráfico se visualiza el cuadro anterior junto con el promedio de las industrias (línea vertical roja). Se observa que cuatro de las industrias registraron un optimismo por sobre el promedio: comercio, bebidas, tecnología y transporte, y manufactura.

*Gráfico 3. ISC por industria*



A continuación, se analizan los resultados dentro de cada industria. Esto es interesante ya que permite comparar empresas que enfrentan desafíos y perspectivas similares, por lo que su grado de optimismo podría reflejar cómo se encuentran posicionados en su industria desde un punto de vista competitivo. Otra hipótesis es que el grado de optimismo pudiera reflejar en qué grado las empresas fueron afectadas por la pandemia de Covid-19, y si fueron capaces de adaptarse a la situación.


## Comercio

En el comercio la empresa cuya carta reflejó mayor optimismo fue Ripley, mientras que la menos optimista fue la de Cencosud Shopping. En el gráfico se observa que tres empresas tuvieron un nivel de optimismo por encima del promedio de la industria: Ripley, Cencosud y Falabella.

*Cuadro 4. ISC del comercio*

Nombre	ISC
Ripley	1.00
Cencosud	0.93
Falabella	0.87
Mall Plaza	0.76
Parque Arauco	0.73
SMU	0.72
Cencosud Shopping	0.50

*Gráfico 4. ISC del comercio*



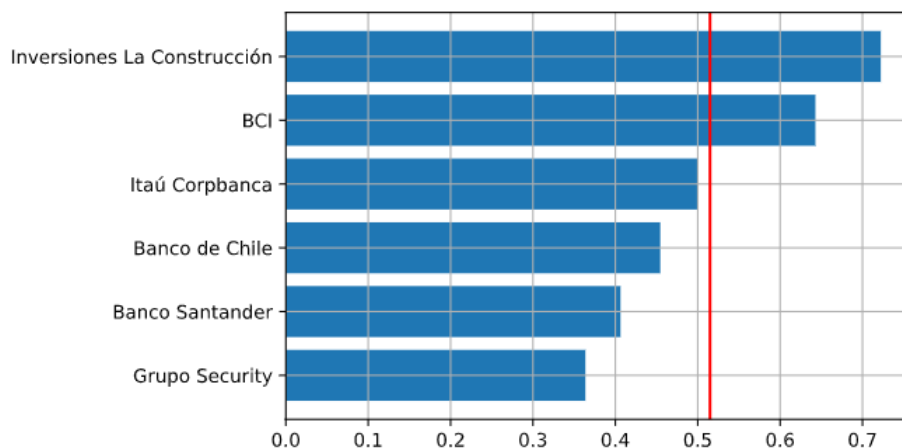
## Financiera

En la industria financiera Inversiones La Construcción fue la empresa cuya carta resultó la más optimista, mientras que la menos optimista se encontró en Grupo Security. Dos empresas se ubicaron por sobre el promedio de optimismo: Inversiones La Construcción y BCI.

*Cuadro 5. ISC de la industria financiera*

Nombre	ISC
Inversiones La Construcción	0.72
BCI	0.64
Itaú Corpbanca	0.50
Banco de Chile	0.45
Banco Santander	0.41
Grupo Security	0.36

*Gráfico 5. ISC de la industria financiera*




## Energía

En el sector Energía la carta más optimista fue la de AES Gener, mientras que la menos optimista fue la de Engie. Esta última empresa fue la única cuyo optimismo se ubicó por debajo del promedio de la industria.

*Cuadro 6. ISC del sector energía*

Nombre	ISC
AES Gener	0.67
Enel Américas	0.60
Colbún	0.60
Engie	0.36

*Gráfico 6. ISC del sector energía*




## Tecnología y Transporte

En el sector de Tecnología y Transporte la empresa con la carta más optimista fue Sonda, mientras que la menos optimista fue CSAV, que también fue la única empresa con un nivel de optimismo por debajo del promedio de la industria.

*Cuadro 7. ISC de los sectores Tecnología y Transporte*

Nombre	ISC
Sonda	0.77
Copec	0.66
Entel	0.65
CSAV	0.45

*Gráfico 7. ISC de los sectores Tecnología y Transporte*



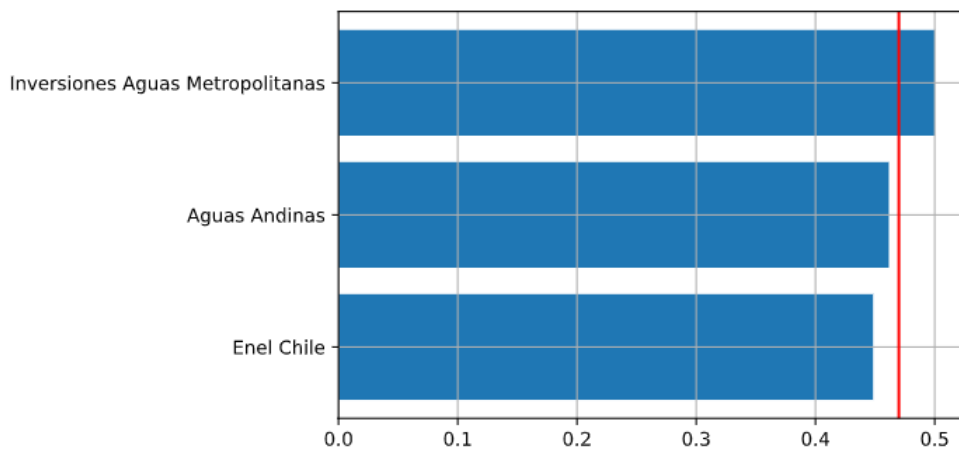
## Servicios básicos

En el sector de los servicios básicos destaca IAM como la empresa con la carta más optimista, y como la única por sobre el promedio de la industria. En contraste, Enel Chile fue la empresa menos optimista. Sin embargo, hay que mencionar que no se observa una gran dispersión del optimismo en este grupo, sino que las empresas muestran un grado de optimismo similar.

*Cuadro 8. ISC de la industria de servicios básicos*

Nombre	ISC
Inversiones Aguas Metropolitanas	0.50
Aguas Andinas	0.46
Enel Chile	0.45

*Gráfico 8. ISC de la industria de servicios básicos*






## Bebidas

En la industria de bebidas la empresa con la carta más optimista fue Concha y Toro, que también fue la única empresa con un optimismo por sobre el promedio de la industria. CCU fue la empresa con menor optimismo.

*Cuadro 9. ISC de la industria de bebidas*

Nombre	ISC
Concha y Toro	0.85
Embotelladora Andina	0.58
CCU	0.57

*Gráfico 9. ISC de la industria de bebidas*




## Manufactura

El sector manufactura se compone de sólo dos empresas, entre las cuales CMPC destacó con la carta con mayor grado de optimismo.

*Cuadro 10. ISC del sector manufacturero*

Nombre	ISC
CMPC	0.65
CAP	0.58

*Gráfico 10. ISC del sector manufacturero*



## Conclusiones

En este estudio se ilustró cómo utilizar un modelo de machine learning para extraer el sentimiento económico implícito en las cartas a los accionistas, y usar dicha información para elaborar un índice de sentimiento corporativo (ISC).

En síntesis, se encontró un ISC promedio de 0.62, y que las tres empresas con las cartas más optimistas fueron Ripley, Cencosud y Falabella, mientras que las empresas con menor optimismo en sus cartas fueron Grupo Security, Engie y Banco Santander. A nivel de industrias, se encontró que los sectores económicos más optimistas fueron el Comercio y la industria de Bebidas, mientras que los sectores menos optimistas fueron el de Servicios Básicos y el Financiero.

Como reflexión se puede comentar que el significado o las implicancias de los índices presentados en este reporte son desconocidas, y deben ser materia de futuros estudios. Sería interesante responder preguntas como: ¿Se puede predecir el desempeño futuro de las empresas o industrias a partir de esta información (ventas, utilidades, precios de las acciones)? ¿Se puede predecir el retorno del IPSA? ¿Se puede predecir la actividad económica, consumo, inversión, empleo u otras variables macroeconómicas?

Respecto a futuras extensiones del estudio, se menciona que se podría profundizar el desarrollo de este índice, construyendo indicadores adicionales a partir de la información que se tiene actualmente, por ejemplo: crear índices de dispersión que midan incertidumbre; entrenar el modelo para identificar textos negativos y luego construir un índice de difusión; o se podría extender el análisis a un conjunto más amplio de empresas (IGPA) o de años.

Por último, se menciona que también sería interesar usar el modelo de machine learning desarrollado en este estudio para analizar el sentimiento de otros textos económicos. Por ejemplo, las noticias de la prensa online—como lo hacen los índices de incertidumbre económica—, la actividad de redes sociales como Twitter o los textos del Informe de Percepciones de Negocios del Banco Central de Chile. En esta tarea sería ideal colaborar con los investigadores que recientemente han realizado trabajos similares.

## Referencias

Baker, S., Bloom, N & Davis, J. (2016). Measuring Economic Policy Uncertainty, *The Quarterly Journal of Economics*, Volume 131, Issue 4, November 2016, Pages 1593–1636, <https://doi.org/10.1093/qje/qjw024>

Becerra, Juan Sebastián & Sagner, Andrés (2020). Twitter-Based Economic Policy Uncertainty Index for Chile. Working Papers N° 883 <https://www.bcentral.cl/en/web/banco-central/content/-/detalle/documento-de-trabajo-n-883>

Cerda, Rodrigo; Silva, Álvaro & Valente, José Tomás (2018). Impact of economic uncertainty in a small open economy: the case of Chile, *Applied Economics*, Taylor & Francis Journals, vol. 50(26), pages 2894-2908, June. <https://doi.org/10.1080/00036846.2017.1412076>

del Pilar Cruz, María; Peralta, Hugo & Ávila, Bruno (2020). Análisis de Sentimiento Basado en el Informe de Percepciones de Negocios del Banco Central de Chile, Working Papers Central Bank of Chile 862, Central Bank of Chile. <https://www.bcentral.cl/en/web/banco-central/content/-/detalle/analisis-de-sentimiento-basado-en-el-informe-de-percepciones-de-negocios-del-banco-central-de-chile>

## Anexos

### Anexo 1. Empresas del IPSA y sus industrias

<b>Empresa</b>	<b>Industria</b>
CCU	Bebidas
Concha y Toro	Bebidas
Embotelladora Andina	Bebidas
Cencosud	Comercio
Cencosud Shopping	Comercio
Falabella	Comercio
Mall Plaza	Comercio
Parque Arauco	Comercio
Ripley	Comercio
SMU	Comercio
AES Gener	Energía
Colbún	Energía
Enel Américas	Energía
Engie	Energía
Banco de Chile	Financiera
Banco Santander	Financiera
BCI	Financiera
Grupo Security	Financiera
Inversiones La Construcción	Financiera
Itaú Corpbanca	Financiera
CAP	Manufactura
CMPC	Manufactura
SQM	Manufactura
Aguas Andinas	Servicios Básicos
Enel Chile	Servicios Básicos
Inversiones Aguas Metropolitanas	Servicios Básicos
Copec	Tecnología y Transporte
CSAV	Tecnología y Transporte
Entel	Tecnología y Transporte
Sonda	Tecnología y Transporte

## Anexo 2. ISC por empresa

Nombre	Industria	ISC
Ripley	Comercio	1.00
Cencosud	Comercio	0.93
Falabella	Comercio	0.87
Concha y Toro	Bebidas	0.85
Sonda	Tecnología y Transporte	0.77
Mall Plaza	Comercio	0.76
Parque Arauco	Comercio	0.73
SMU	Comercio	0.72
Inversiones La Construcción	Financiera	0.72
AES Gener	Energía	0.67
Copec	Tecnología y Transporte	0.66
CMPC	Manufactura	0.65
Entel	Tecnología y Transporte	0.65
BCI	Financiera	0.64
Enel Américas	Energía	0.60
Colbún	Energía	0.60
CAP	Manufactura	0.58
Embotelladora Andina	Bebidas	0.58
CCU	Bebidas	0.57
Itaú Corpbanca	Financiera	0.50
Inversiones Aguas Metropolitanas	Servicios Básicos	0.50
Cencosud Shopping	Comercio	0.50
Aguas Andinas	Servicios Básicos	0.46
Banco de Chile	Financiera	0.45
CSAV	Tecnología y Transporte	0.45
Enel Chile	Servicios Básicos	0.45
Banco Santander	Financiera	0.41
Grupo Security	Financiera	0.36
Engie	Energía	0.36